ФАЛЬКОН tex

ПРОЕКТ МЭРА МОСКВЫ | БИЗНЕС МОСКВЫ | РАЗВИТИЕ ЧЕЛОВЕЧЕСКОГО КАПИТАЛА | ЛИДЕРЫ ЦИФРОВОЙ ТРАНСФОРМАЦИИ



КОМАНДА «МЕЧТЫ»

7. Сервис формирования цифрового признака транспортного средства для сопоставления снимков одного автомобиля из разных локаций без использования государственного номера



О команде

- **Капитан:** Парамонов Даниил Максимович, специальность Математика и компьютерные науки
- **Кол-во участников:** 3 человек
- **Краткое описание:**

📫 Команда образовалась благодаря знакомству на стажировке

📫 Центральный университет

- **Город и регион:** Москва

КОМАНДА «МЕЧТЫ»

Краткое описание решения:

Сервис для поиска одного и того же автомобиля на снимках с разных камер без использования государственного номера. Модель формирует визуальный эмбеддинг автомобиля, сравнивает его с галереей и возвращает наиболее похожих кандидатов либо отказ, если уверенного совпадения нет

Уникальность решения:

Мы собрали полноценный сервис, корректно интегрированный в ML-модель: общая индексируемая галерея, одиночный и пакетный поиск, умная функция потерь, переранжирование кандидатов, дообучение на доп датасетах, отдельная политика отказа от сомнительных совпадений и готовый веб-интерфейс для просмотра результатов

КОМАНДА «МЕЧТЫ»



Даниил Парамонов

- Full-stack Developer
- @Rayfaga
- +7(903)608-78-86
- Центральный университет



Мария Адюкова

- ML Engineer
- @hissikly
- +7(961)347-73-34
- Центральный университет



Елизавета Кутузова

- Product Manager
- @lizkutuzova
- +7(968)743-98-55
- Центральный университет

КОМАНДА «МЕЧТЫ»

ПРОЕКТ МЭРА МОСКВЫ · БИЗНЕС МОСКВЫ · РАЗВИТИЕ ЧЕЛОВЕЧЕСКОГО КАПИТАЛА · ЛИДЕРЫ ЦИФРОВОЙ ТРАНСФОРМАЦИИ

Краткая история команды: 01

Мы познакомились благодаря кейс-чемпионату и стажировке в Московской бирже. Тогда мы работали в разных командах, а на ЛЦТ решили объединиться, потому что наши компетенции дополняют друг друга.

Почему вы выбрали именно эту задачу из предложенных на хакатоне? 02

Нам было интересно поработать с нестандартной ML-задачей и данными, приближенными к реальному городскому сценарию. Кейс хорошо совпал с компетенциями команды и позволил каждому участнику применить свою экспертизу в рамках одного решения

С какими основными сложностями или вызовами вы столкнулись и как их преодолели? 03

Самой сложной частью стала работа с сильно различающимися изображениями одного и того же автомобиля. На результат влияли ракурс, качество кадра, освещение и сходство между разными машинами

КОРОТКО О РЕШЕНИИ

Техническая суть решения

ML: изображение автомобиля преобразуется дообученным DINOv2-L в 1024-мерный эмбеддинг. Система сравнивает его с векторами автомобилей в галерее, ранжирует Top-10 кандидатов и применяет отдельную политику отказа, чтобы не выдавать сомнительные совпадения. Для пакетного поиска дополнительно используется AQE, уточняющий ранжирование по ближайшим соседям

Интерфейс: пользователь один раз формирует общую галерею автомобилей, после чего может работать в двух режимах – искать по одному изображению с ручным выделением BBox или загружать группу кадров вместе с CSV. Сервис визуализирует Top-10 кандидатов с ID и cosine similarity, позволяет подробно сравнить изображения и экспортировать результаты

Маркетинговая суть решения

Проект ориентирован на государственные учреждения и организации, работающие с городскими системами видеонаблюдения, включая операторов таких систем и сотрудников ГИБДД. Сервис сокращает объём ручного поиска автомобиля и ускоряет работу в сложных визуальных условиях

Сервис может использоваться как дополнительный модуль к существующим системам видеонаблюдения и ALPR в случаях, когда государственный номер невозможно надёжно распознать

Для B2G-модели характерны длительный цикл сделки и высокие требования к безопасности данных и соблюдению законодательства. Для выхода на рынок важно подтвердить экономическую эффективность решения и возможность масштабирования на большие объёмы данных

Пользовательский путь

1

Формирование галереи

Пользователь загружает изображения автомобилей и BBox-разметку. Система формирует базу эмбеддингов для дальнейшего поиска

2

Загрузка запроса

Пользователь выбирает одиночный или пакетный режим. Для одного изображения автомобиль можно выделить вручную, а можно подгрузить изображения с BBox-разметкой

3

Поиск совпадений

Система формирует эмбеддинг автомобиля и сравнивает его с объектами галереи

4

Получение кандидатов

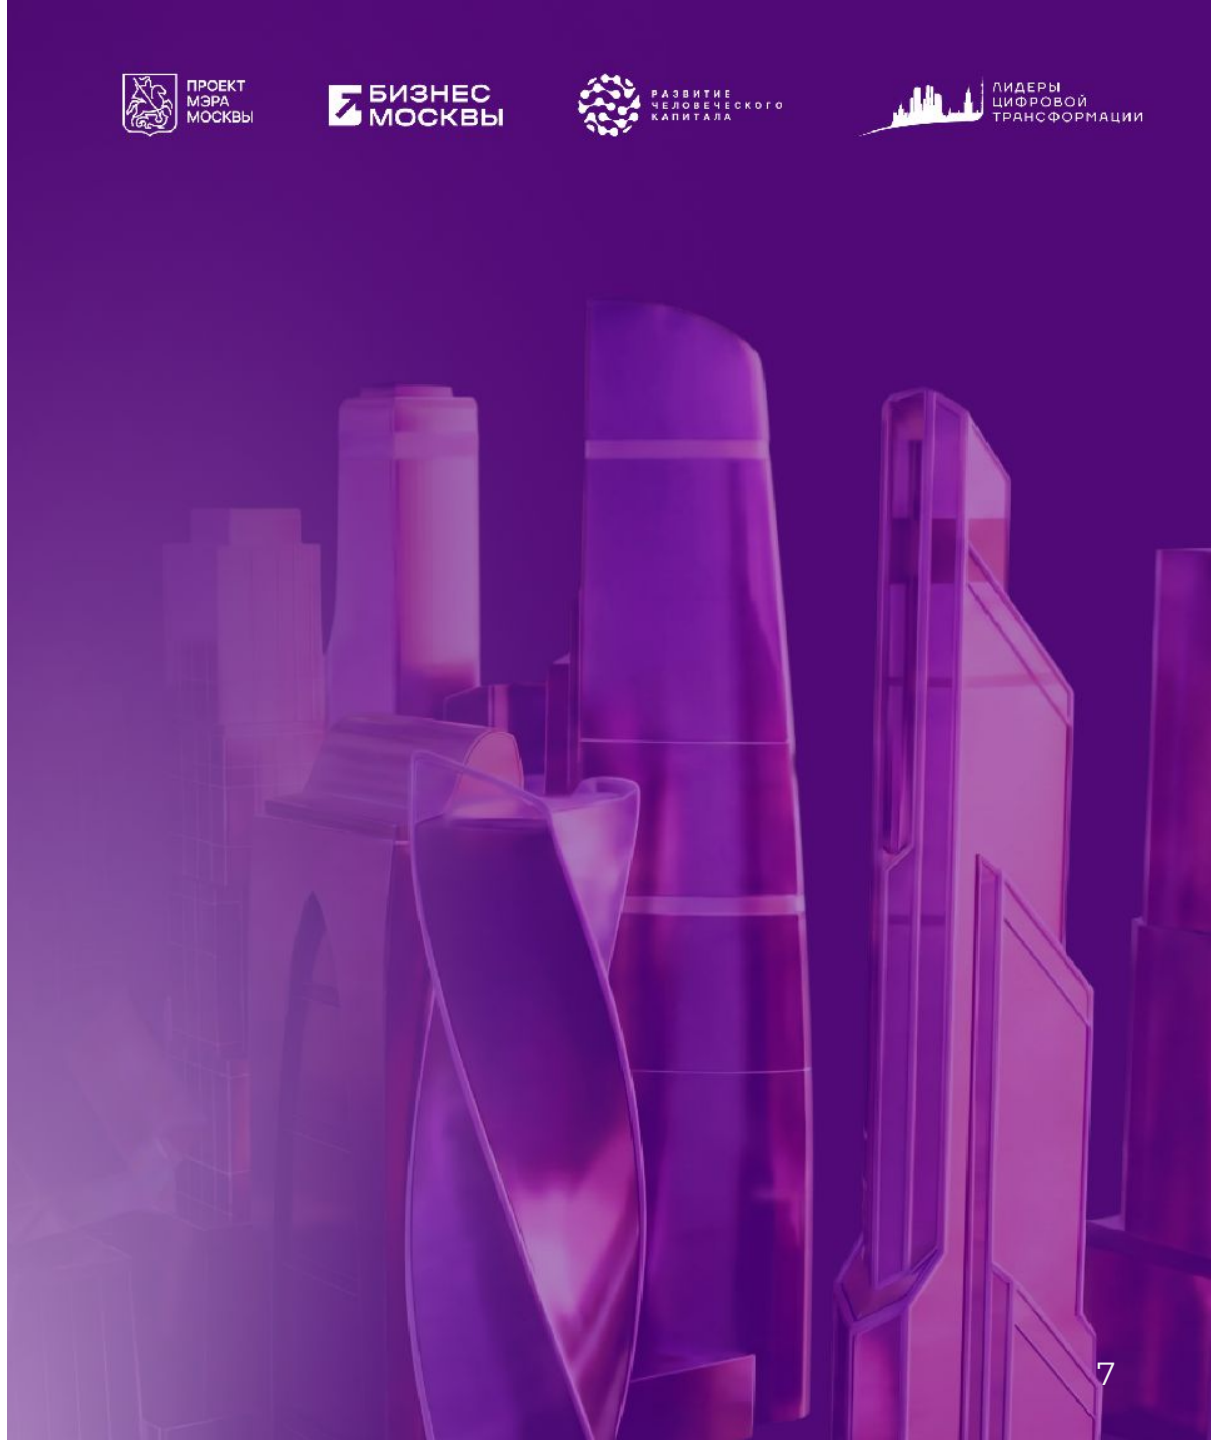
Пользователь получает Top-10 наиболее похожих автомобилей, отсортированных по cosine similarity. Если достаточно уверенного совпадения нет, система возвращает отказ

5

Проверка кандидатов

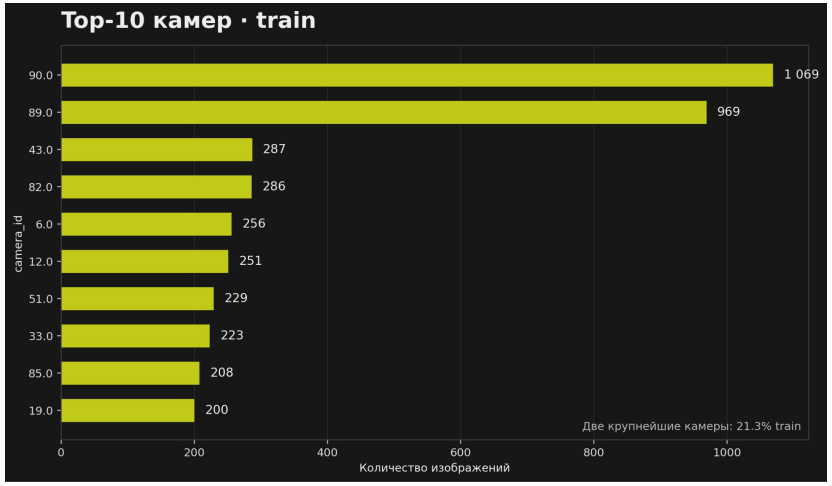
Пользователь сравнивает найденные изображения и принимает решение на основе предложенных системой кандидатов

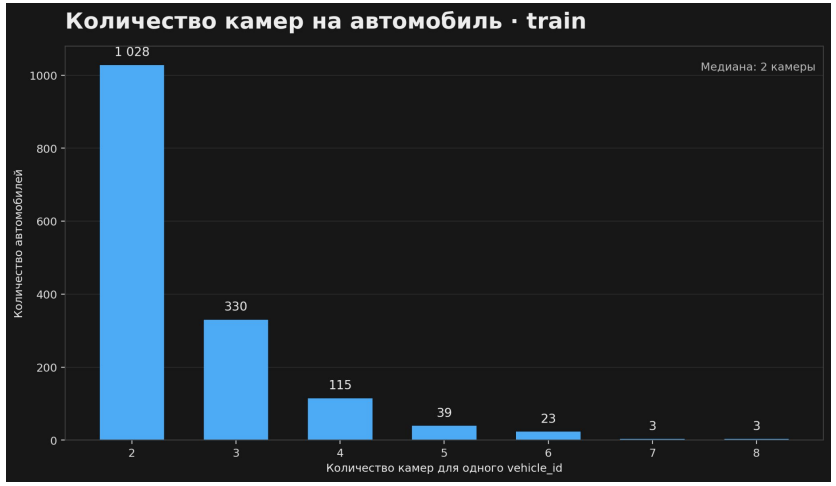
ОБРАБОТКА И ОЧИСТКА ДАННЫХ



Данные

Всего изображений	Train-кадров	Автомобилей в train	Камер	Query	Gallery	Разрешение
11 416	9 556	1 541	96	1 110	750	1920×1080





Похожие кадры внутри камеры

Одна камера:
1 980 / 8 011 → 24,7%

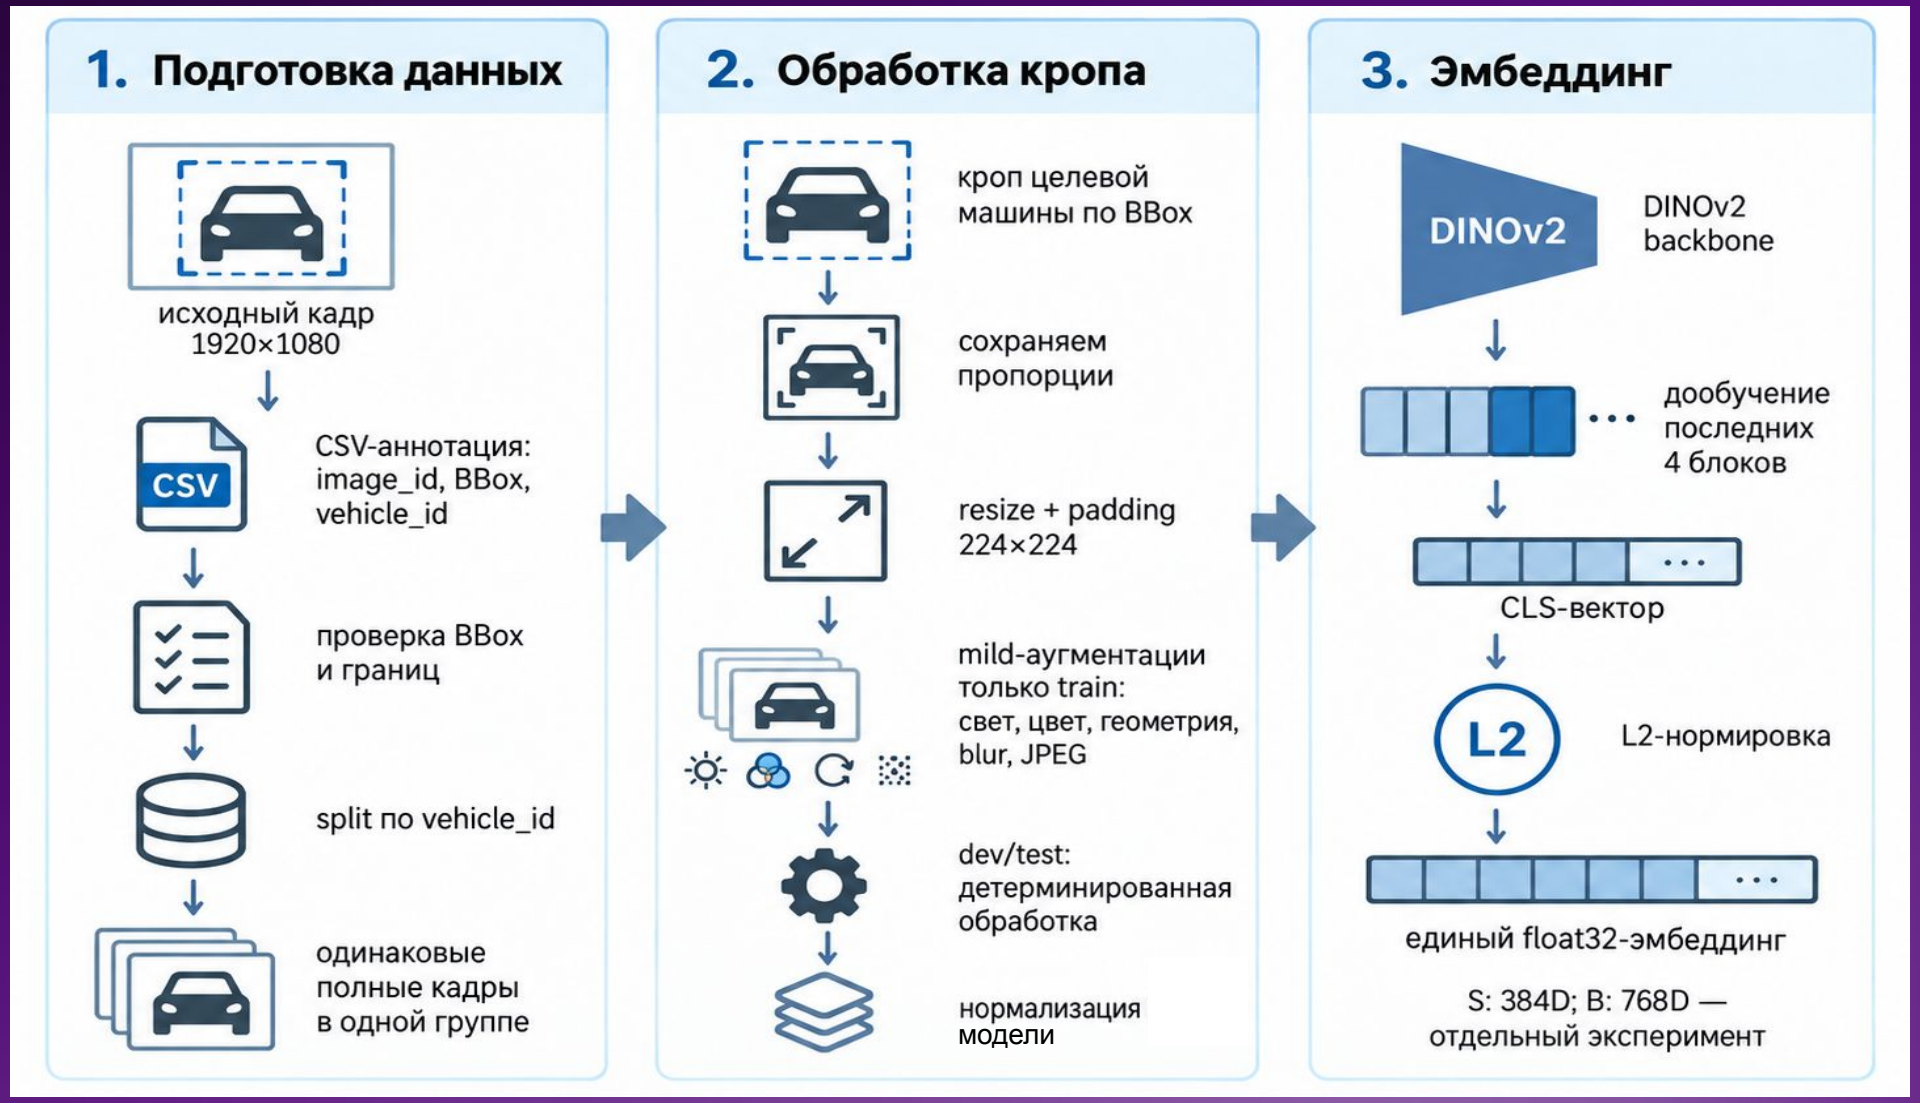
Разные камеры:
0 / 17 879 → 0%

Примеры «почти дубликатов» в данных





Обработка данных



Выборки и защита от завышения метрики

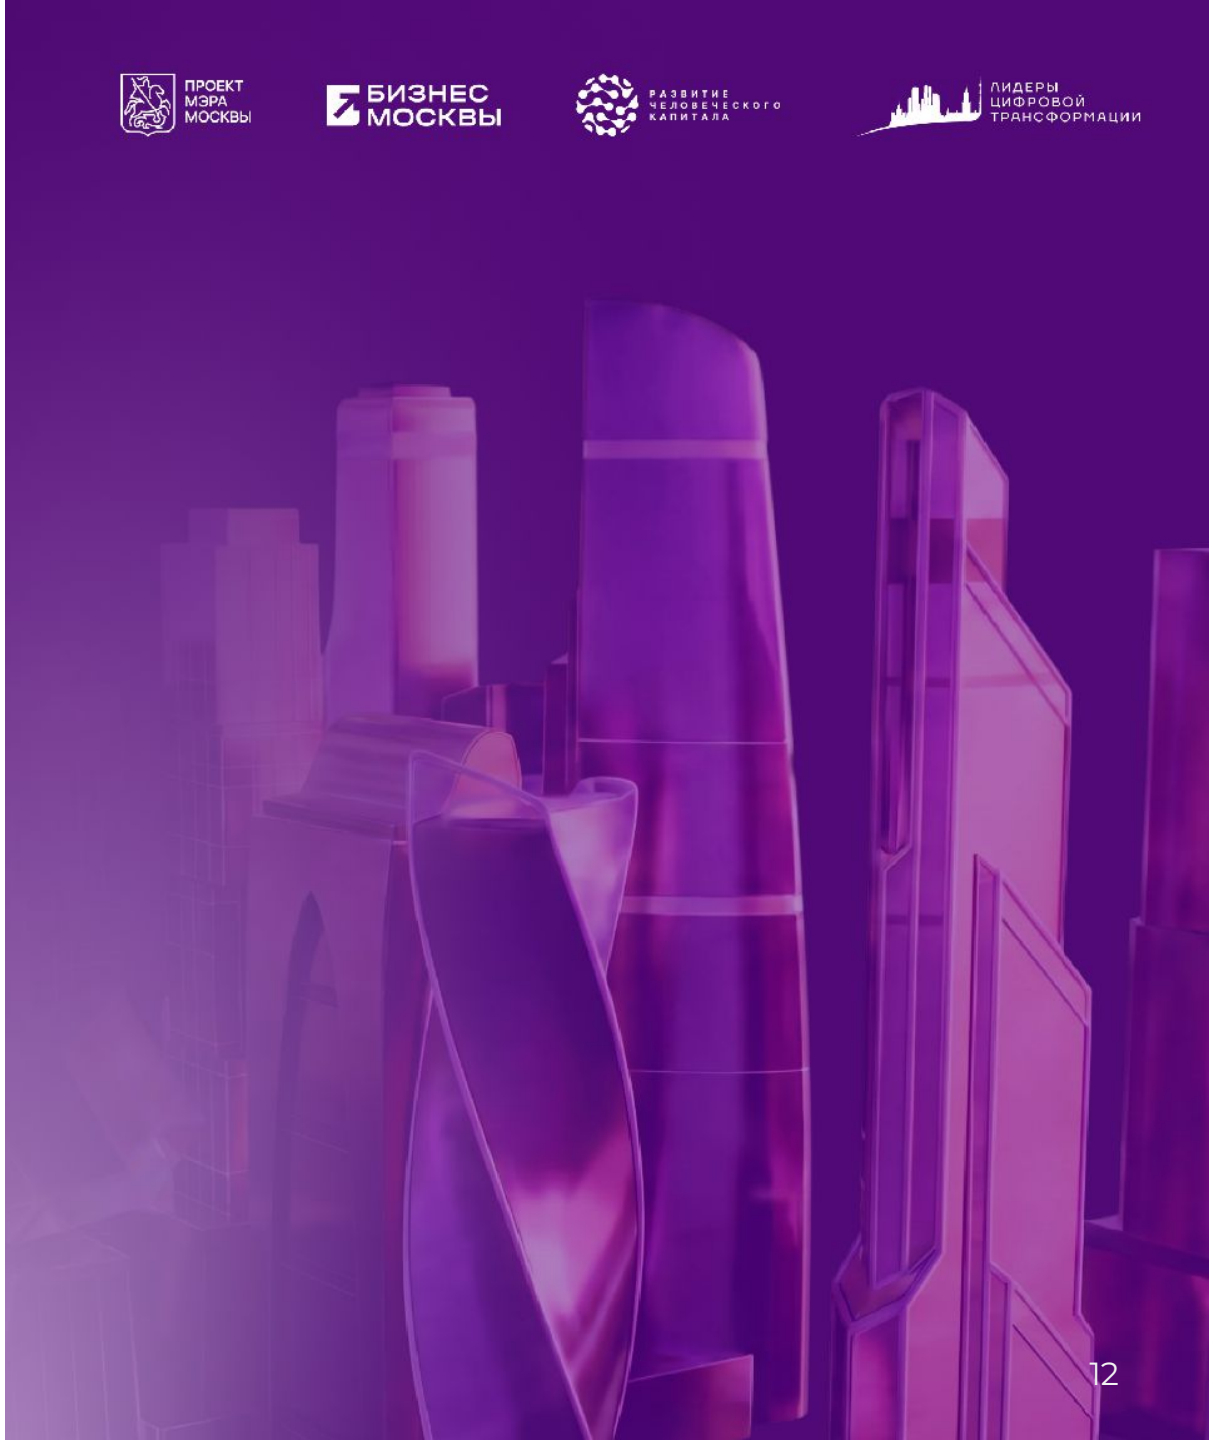
Внутренние выборки

Train	6 209 фото / 1 001 ID	обучение модели
Dev	1 449 фото / 231 ID	выбор checkpoint
Calibraiton	929 фото / 154 ID	порог отказа
Holdout	969 фото / 155 ID	финальная проверка, закрыт

4 уровня борьбы с дубликатами

- 1. vehicle_id – один автомобиль не попадает одновременно в train и dev
- 2. Одинаковые исходные кадры группируются и не разделяются между фолдами
- 3. Same-camera кандидаты исключаются при mAP: оцениваем cross-camera ReID
- 4. Mild-аугментации меняют свет, цвет, геометрию, blur, JPEG и часть BBox

МОДЕЛЬ И ЭКСПЕРИМЕНТЫ



От изображения к списку кандидатов



Первая точка отсчёта: frozen DINOv2-S

DINOv2-S/14 · CLS · 224 px · frozen encoder

8,40%

cross-camera mAP на dev

9,87%
Rank -1

16,91%
Rank -5

90,13% запросов без правильного автомобиля на первом месте

Разморозили 4 последних слоя:

DINOv2-S fine-tuning: mAP 48,10% Rank-1 = 56,38%

Аугментации

Baseline - одинаковые настройки, кроме аугментаций

	С аугментациями	Без аугментаций
Dev mAP	**53,51%**	48,10%
Rank-1	**56,38%**	50,66%



organizer crop | mild #1 | mild #2 | mild #3 | mild #4

Сравнение моделей

Метрика	DINOv2 S frozen	DINOv2 S mild	DINOv2 S none	DINOv2 B	DINOv2 B	DINOv2 B336	CNX-B	Open CLIP	Trans ReID	DINOv2 L336	DINOv2 L336 E2
mAP	8,40%	56,40%	48,10%	63,63%	63,14%	66,99%	36,26%	46,43%	24,79%	69,28%	**70,46%**
Rank-1	9,87%	59,97%	50,66%	65,98%	65,22%	68,94%	39,27%	46,24%	26,64%	69,70%	**70,39%**
Rank-5	16,91%	73,98%	68,60%	81,09%	78,81%	81,99%	55,28%	67,08%	41,48%	84,89%	**85,44%**
Эпохи	-	10	6	10	20	10	20	10	3	10	**16**

Как обучали модель

8 машин × 4 фото = 32 кадра

Один vehicle_id = один набор

Все кадры одного vehicle_id оставались в одном наборе. DINO не видел на обучении машины из dev

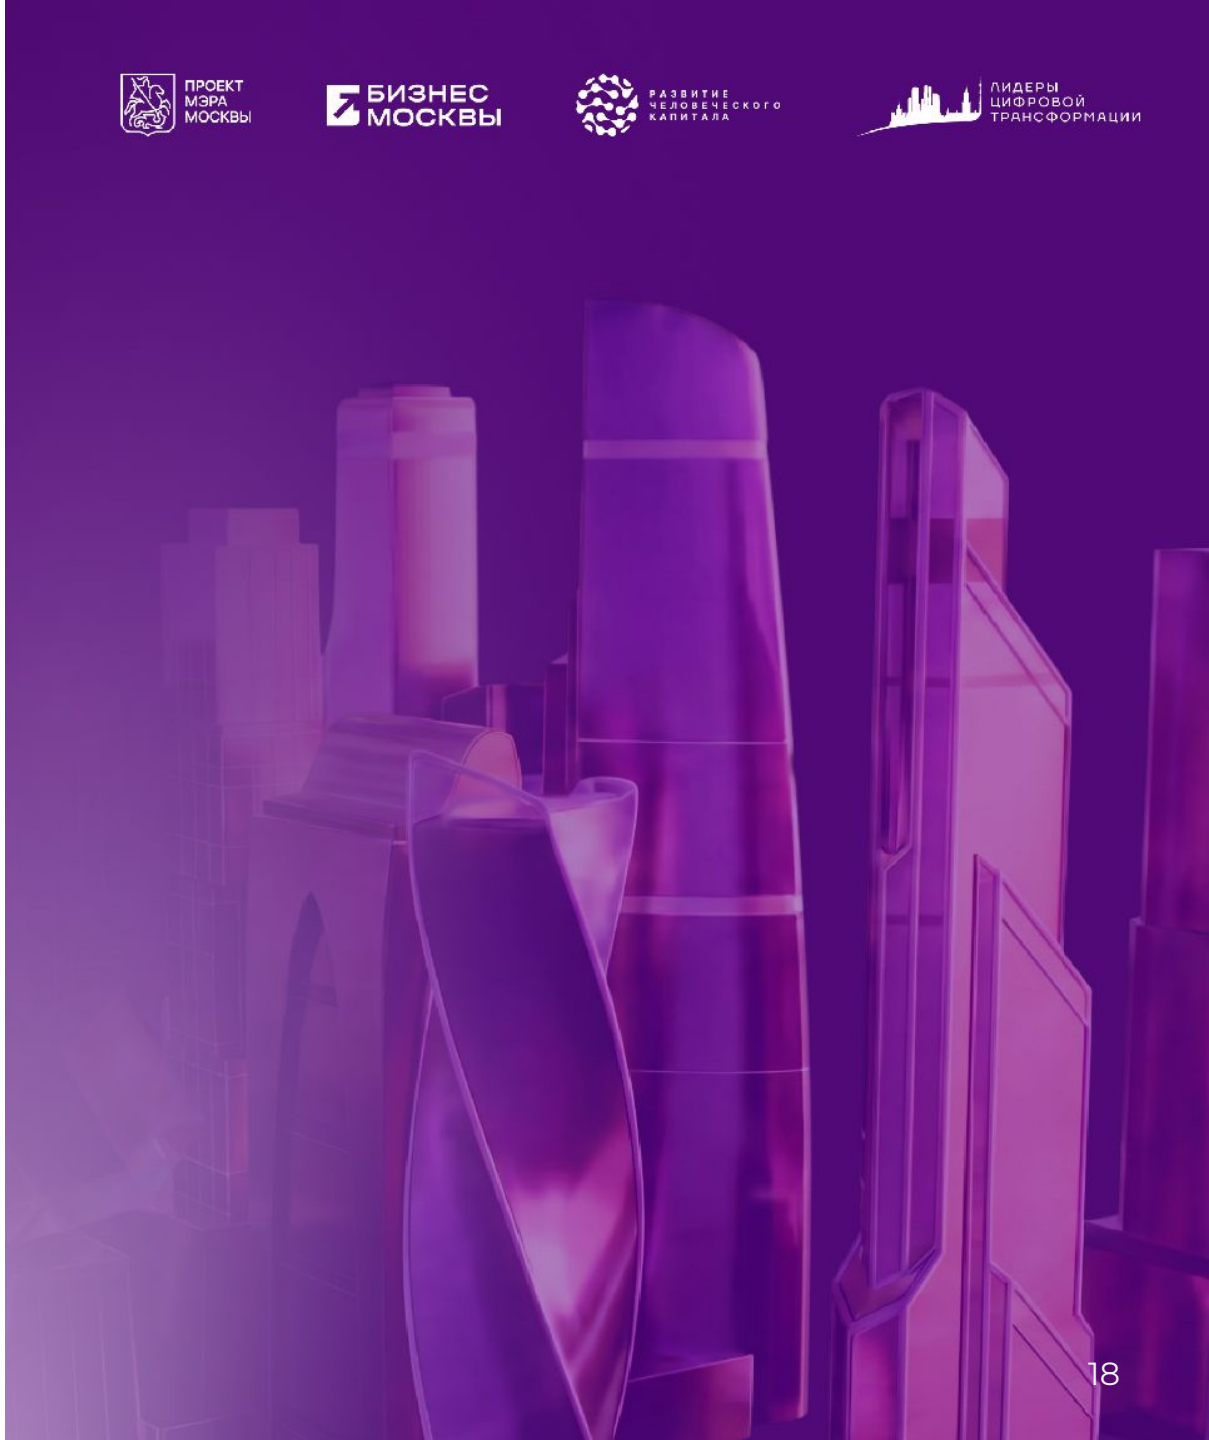
Оптимизатор, эпохи, вход, lr

- AdamW
- 20 эпох
- 336×336 px
- learning rate backbone 1e-5

Дообучали 4 последних блока.

Временная классификационная голова училась относить изображения к ID машины

АНАЛИЗ ОШИБОК И РЕЖИМ ОТКАЗА



Какие ошибки встречаются чаще всего

Трудные случаи:

- Смена ракурса
- Внешне похожие машины
- В кадре несколько машин или есть перекрытие
- Проблемы исходных примеров: у некоторых кропов возникли подозрения на несоответствие ID или целевого автомобиля









у фото ID 738

Ещё интересные примеры

Пример 1

Модель приняла похожую, но другую машину



Пример 2

Верная машина найдена, но система отказала. У запроса ID 595 правильный кандидат оказался чуть ниже порога отказа



Отказ тем, кого нет в галерее

Политика	Pair-F1	Query-F1	TNR
Cosine-порог	0,506	**0,668**	0,661
Логистический гибрид	**0,547**	0,653	0,661
HistGradientBoosting	0,533	0,663	0,661

Признаки для обучения:

- **Cosine кандидата:** скалярное произведение нормированного эмбеддинга запроса и кандидата
- **Cosine первого кандидата**
- **Средний cosine Top-10**
- **Стандартное отклонение cosine Top-10**
- **Разница между оценкой кандидата и Top-1**

Почему HistGradientBoosting?

Неглубокий градиентный бустинг дал прирост Pair-F1 относительно cosine, сохранив TNR; Поэтому бустинг выбрали как компромисс между гибридом и косинусом

Реранкер: контекст меняет порядок

Проблема: смена ракурса и похожие авто сбивают Top-1

E2-эмбеддинги → граф взаимных соседей (k_1=20, k_2=6) → новый Top-K

итоговая дистанция = 30% косинус между эмбеддингами + 70% Jaccard

mAP 70,46 → 73,58%
Rank-1 70,39 → 71,84%
Rank-5 85,44 → 82,82%

Дополнительные данные

ПРОЕКТ МЭРА МОСКВЫ · БИЗНЕС МОСКВЫ · РАЗВИТИЕ ЧЕЛОВЕЧЕСКОГО КАПИТАЛА · ЛИДЕРЫ ЦИФРОВОЙ ТРАНСФОРМАЦИИ

CityFlow

- Городские и дорожные камеры; 85 058 изображений, 440 машин
- Соседние изображения могут быть очень похожи друг на друга

VRIC

Данные с сильной вариативностью масштаба, размытия, освещения, перекрытий и ракурса

54 494 изображения; 2 649 ID

Обучение	Dev: mAP / Rank-1 / Rank-5	Calibration: mAP / Rank-1 / Rank-5
Ориг	70,46 / 70,39 / 85,44	78,00 / 78,36 / 91,93
Ориг F+ CityFlow	73,15 / 73,57 / 86,82	80,32 / 81,70 / 93,11
Ориг + CityFlow + VRIC	70,81 / 70,46 / 85,92	77,51 / 79,76 / 91,39

Сильные аугментации

Внутренние выборки

Усилили два типа преобразований:

- **Цвет:** *Color Jitter* — яркость 0,4, контраст 0,4, насыщенность 0,25, оттенок 0,04.
- **Случайное стирание части изображения:** вероятность 50%, площадь области до 25% кадра

Остальные аугментации как mild:

- небольшое affine-изменение: поворот до 3°, сдвиг до 2,5%, масштаб 0,95–1,05;
- лёгкое размытие: вероятность 15%, Gaussian blur sigma 0,2–1,0;
- JPEG-сжатие: вероятность 20%, качество 55–95

Метрика	Mild	Strong
Dev mAP	73,15%	74,05%
Calibration mAP	80,32%	81,37%
Calibration Rank-5	93,11%	92,14%

Реранкер: контекст меняет порядок

Метод	Dev mAP	Dev Rank-1	Dev Rank-5	Calibration mAP	Calibration Rank-5
Cosine, без reranker	73,15%	73,57%	86,82%	80,32%	93,11%
k-reciprocal, граф взаимных соседей	76,73%	75,16%	84,47%	83,46%	91,50%
AQE, граф с запросами и галереей	77,33%	76,67%	87,03%	83,58%	92,79%
AQE, запрос отдельно от галереи	74,92%	74,53%	84,89%	81,97%	90,96%

AQE - уточняет эмбеддинг изображения по его ближайшим соседям

Идея: если векторы признаков фото близки, их можно усреднить, чтобы поиск меньше зависел от особенностей одного кадра

Для нормированного эмбеддинга z мы брали 5 ближайших соседей и считали:

$$z' = \text{normalize}\left(0.75z + 0.25 \cdot \frac{1}{5}\sum_{j=1}^{5} z_j\right)$$

Потом сравнивали уже уточнённые векторы по cosine

Что мы проверили, но не оставили

Проверка	Dev-результат	Суть
PCA-whitening	Frozen S: 8,40 → 17,54%; fine-tuned S: 56,40 → 35,46%	Дополнительная обработка эмбеддингов для поиска
BN-neck	mAP 56,40% → 55,87%; TNR 62,82% → 68,13%	Нормировка эмбеддинга слоем BatchNorm
Hard-negative mining	B336: 66,99% → 65,69%	Добавили в обучение пары похожих, но разных машин
E3: только ID-loss	48,80% mAP; остановка 6/16. E2 с metric loss: 70,46%	Убрали metric loss

Итоговое решение

Фото + BBox

↓

DINOv2 ViT-L/14, 336×336

дообучение с сильными аугментациями

↓

эмбеддинг 1024D

↓

AQE по 5 ближайшим соседям

↓

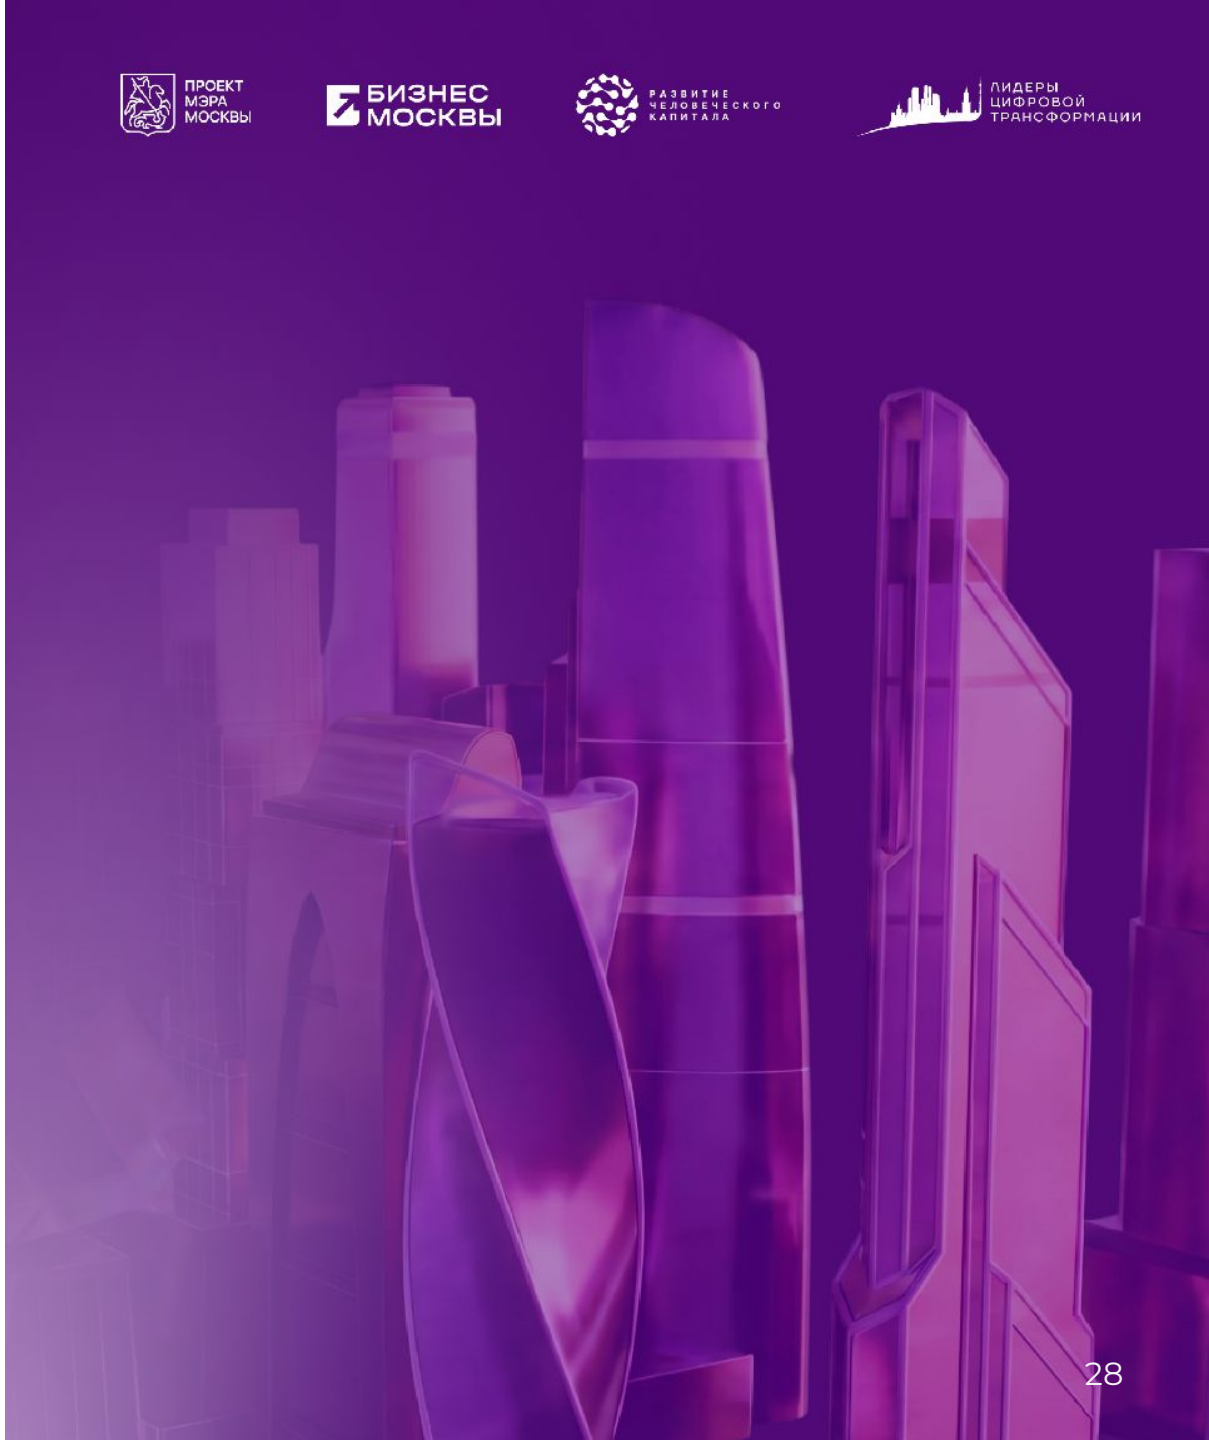
cosine-ранжирование + политика отказа

↓

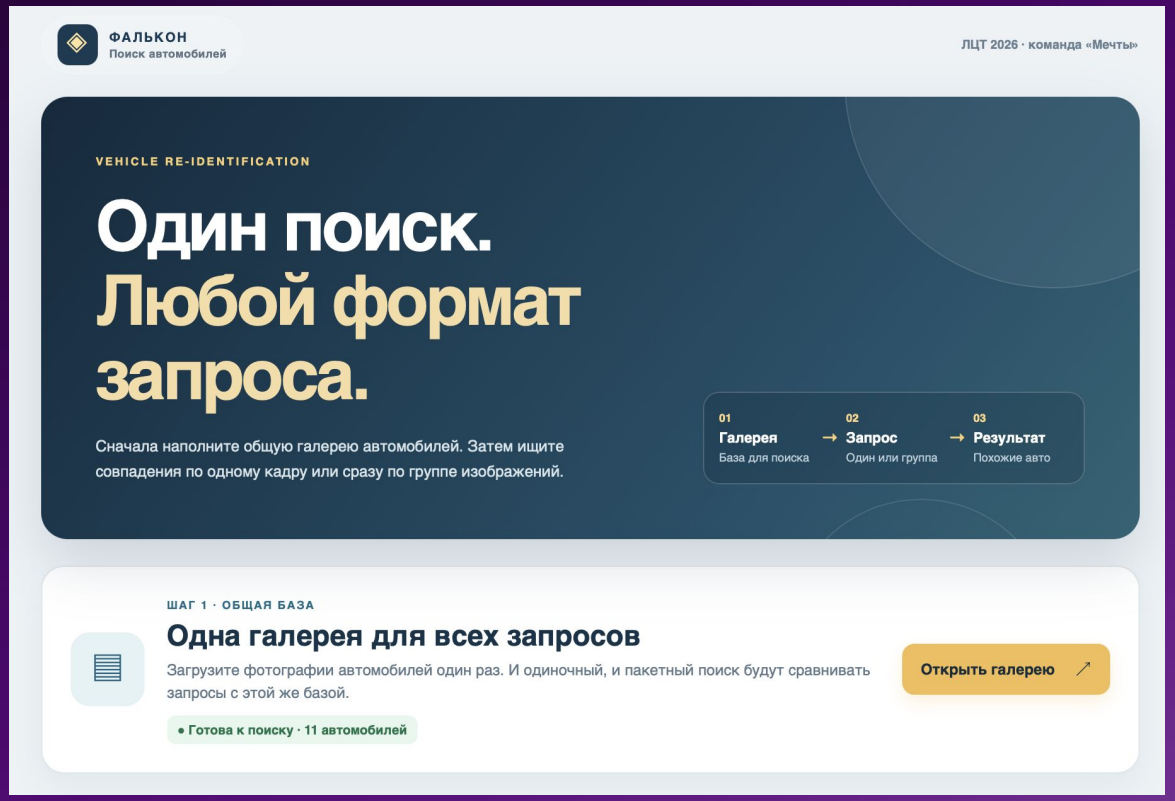
Top-K кандидатов

Внутренняя выборка	Метрика	Strong + AQE
Dev	mAP	77,63%
	Rank-1	77,02%
	Rank-5	87,16%
Calibration	mAP	84,65%

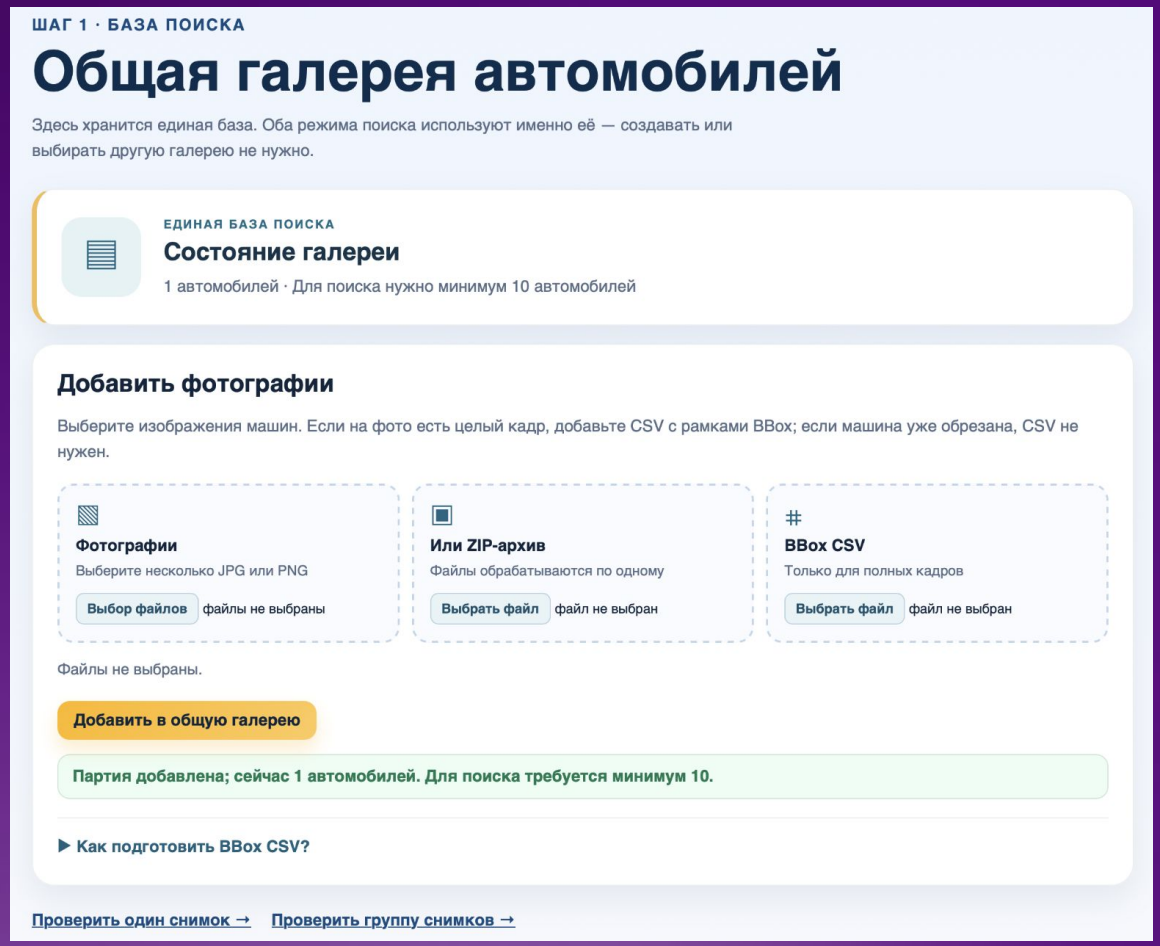
ПРОДУКТ И МАСШТАБИРОВАНИЕ



Интерфейс сервиса

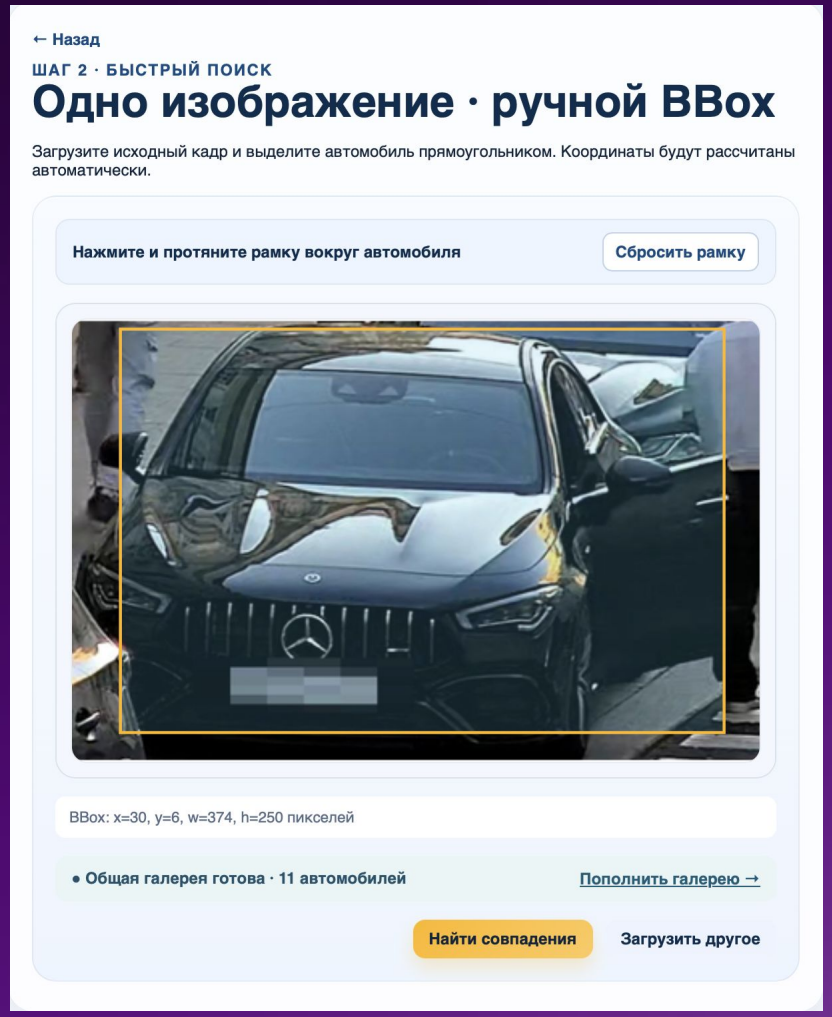


Главный экран

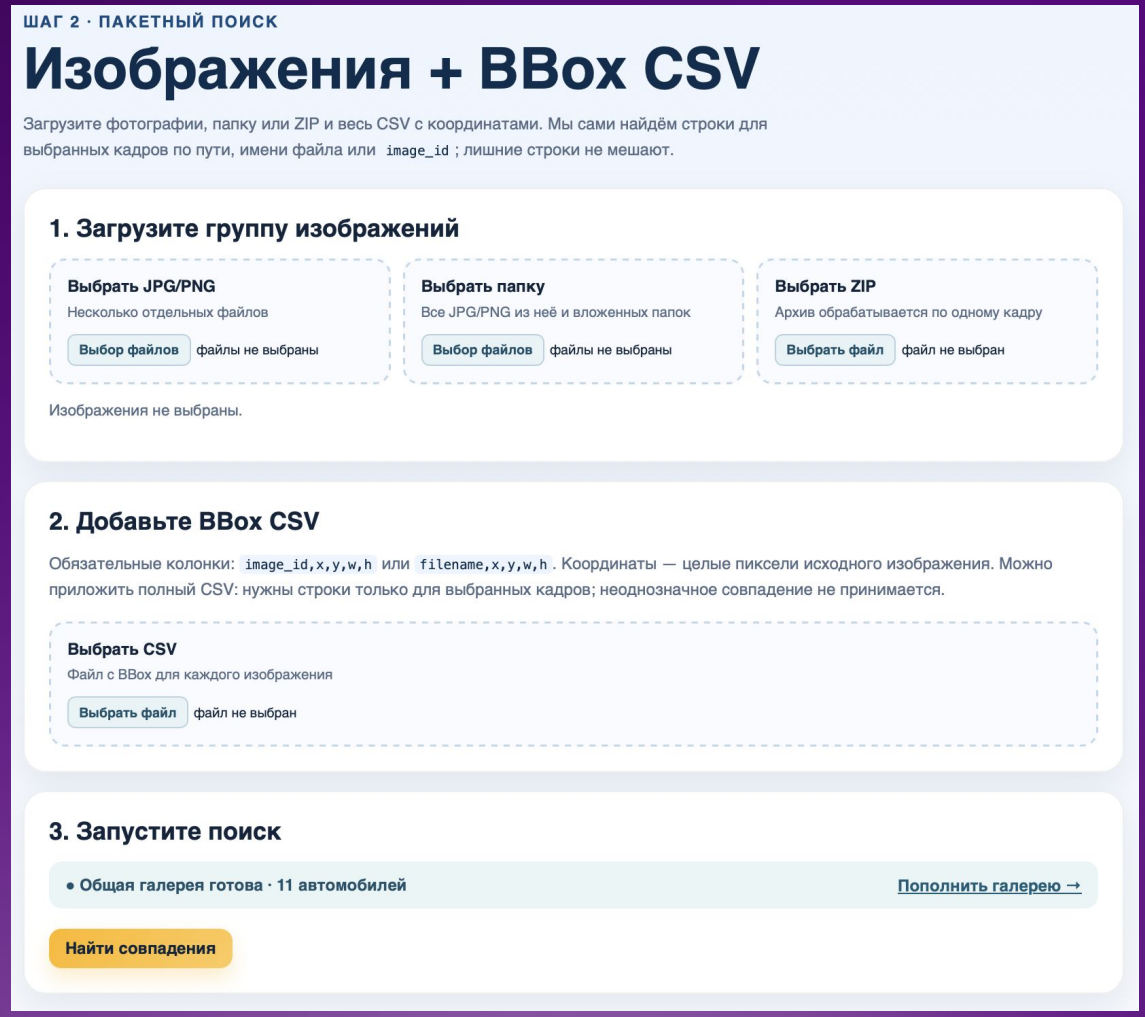


Формирование общей галереи для поиска

Интерфейс сервиса

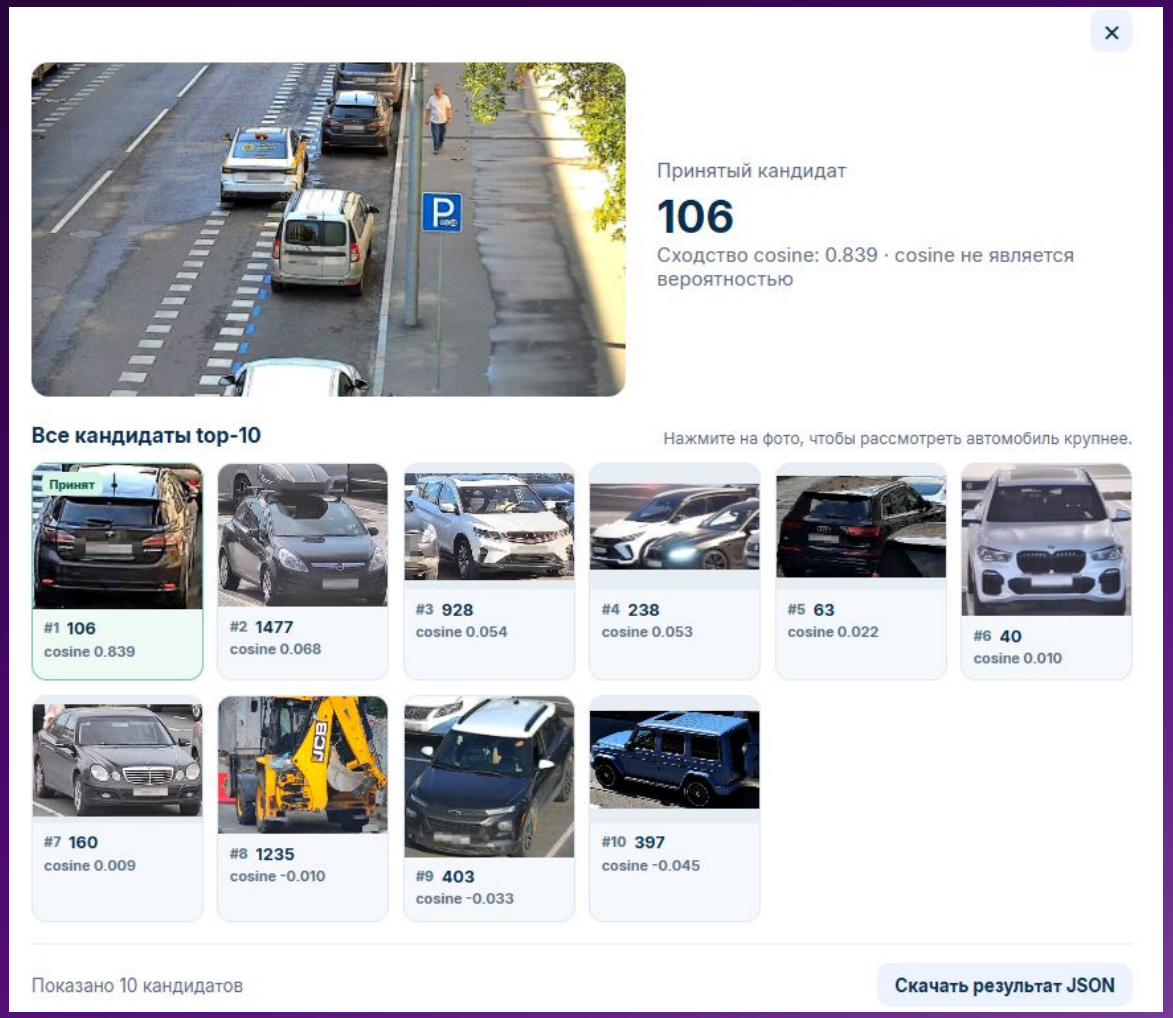


Выделение автомобиля и одиночный поиск

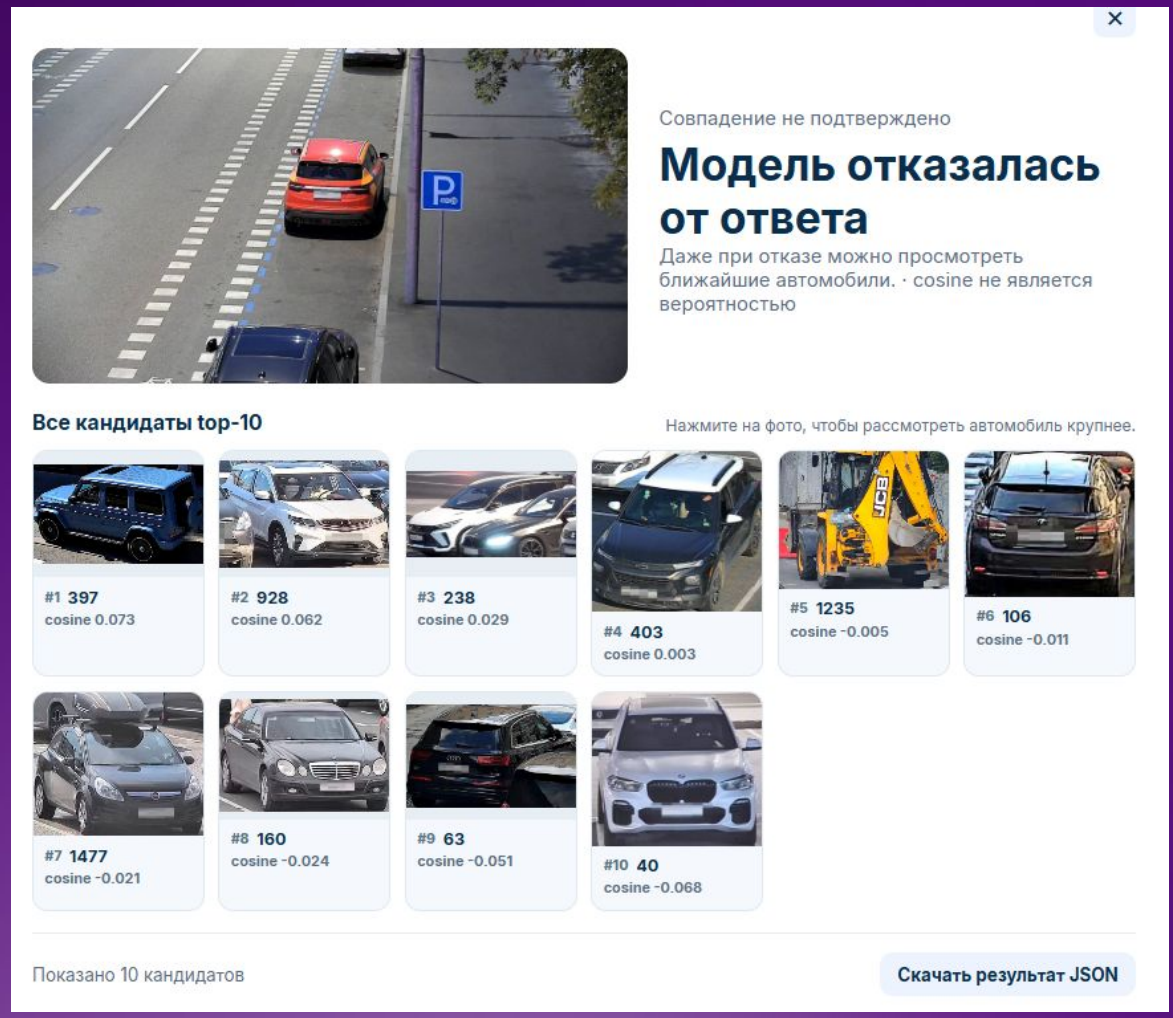


Пакетный поиск

Интерфейс сервиса



Top-10 кандидатов и оценка cosine similarity



Пример выдачи отказа

План масштабирования поиска

ПРОЕКТ МЭРА МОСКВЫ · БИЗНЕС МОСКВЫ · РАЗВИТИЕ ЧЕЛОВЕЧЕСКОГО КАПИТАЛА · ЛИДЕРЫ ЦИФРОВОЙ ТРАНСФОРМАЦИИ

1. Сейчас

- JPEG + BBox
- 1024D-вектор
- Cosine / batch-AQE

2. Индексация

- Потоковые GPU-батчи
- Шарды векторов
- Версия модели и BBox

3. Поиск по 1 млн

- FAISS shortlist
- Точный cosine top-K
- Без N^2-матрицы

4. Ввод в сервис

- Локальный AQE
- F1/TNR и p95/RAM
- Откат к cosine

1 млн × 1024 × FP32 ≈ 4,1 ГБ только на векторы, без индекса и метаданных

Гейт: recall@10 против точного поиска, mAP / Rank-5 / F1 / TNR, p95 и пик RAM на реальных данных

Что можно было сделать ещё

- Обучаемый реранкер для Top-K
- Попробовать другие модели отказа
- Усложнить аугментации
- Попробовать найти больше данных
- Сравнить другие metric loss
- Проверить устойчивость к ухудшению входных фото

